



Documento de Especificación de Requerimientos de Software (SRS)

Evidencia escrita - Avance 1

Toma de requerimientos
Sistema de Extracción de Datos mediante OCR (URL a XML)

Nombre del Estudiante: Hyans Nicolás Parra Valdivia

Docente Guía: Edgar Antonio Varela Pérez

Carrera: Analista Programador

Centro de Práctica: Gestpyme

Fecha: 27 de Abril de 2026

Contenido

1. Introducción

- 1.1 Propósito
- 1.2 Alcance
- 1.3 Definiciones, Acrónimos y Abreviaturas
- 1.4 Referencias

2. Descripción General

- 2.1 Perspectiva del Producto
- 2.2 Funcionalidades del Producto
- 2.3 Características del Usuario
- 2.4 Restricciones

3. Requerimientos Funcionales

- Caso de Uso 1: Extracción de texto mediante OCR en memoria
- Caso de Uso 2: Estructuración de datos y formateo XML

4. Requerimientos de Interfaz de Usuario

- Requerimiento de Interfaz 1: Interfaz de Configuración y Salida por Consola

5. Requerimientos No Funcionales

- RNF1: Rendimiento y procesamiento en memoria RAM
- RNF2: Resiliencia ante fallas de red
- RNF3: Compatibilidad y portabilidad

1. Introducción

1.1 Propósito

Este documento describe los requerimientos de software para el prototipo del Sistema de Extracción de Datos mediante OCR (URL a XML). Se especifican las funcionalidades principales, el manejo de datos en memoria y las restricciones para asegurar el éxito del desarrollo de software en Gestpyme.

1.2 Alcance

El sistema está diseñado para conectarse a URLs públicas de documentos contables (boletas, facturas), realizar la descarga de los mismos directamente a la memoria RAM de manera temporal, extraer su texto plano utilizando el motor Tesseract OCR, y formatear la salida directamente en etiquetas XML estructuradas para su posterior importación automática, eliminando la digitación manual y asegurando la continuidad operacional de la empresa Gestpyme.

1.3 Definiciones, Acrónimos y Abreviaturas

SRS: Especificación de Requerimientos de Software (Software Requirements Specification).

OCR: Reconocimiento Óptico de Caracteres (Optical Character Recognition).

XML: Extensible Markup Language (Lenguaje de Marcado Extensible; formato jerárquico y estructurado para el intercambio de datos).

RAM: Memoria de Acceso Aleatorio (Random Access Memory; memoria de trabajo volátil y de alta velocidad del sistema).

RF o R: Requerimiento Funcional (declara una acción o comportamiento directo que el sistema debe ejecutar).

- **R1:** El sistema deberá permitir al usuario ingresar la dirección URL de un documento contable remoto.
- **R2:** El sistema deberá procesar la imagen descargada en memoria volátil sin persistencia en el almacenamiento secundario.
- **R3:** El sistema deberá ejecutar la extracción OCR utilizando parámetros específicos de idioma en español.
- **R4:** El sistema deberá estructurar y validar el texto extraído dentro de un contenedor jerárquico XML normalizado.

RNF: Requerimiento No Funcional (especifica criterios de operación, restricciones tecnológicas o propiedades de calidad del software).

- **RNF1:** Rendimiento y procesamiento en memoria RAM.
- **RNF2:** Resiliencia ante fallas de red.
- **RNF3:** Compatibilidad y portabilidad.

- **Pipeline:** Flujo de trabajo o cadena de procesos secuenciales conectados entre sí, donde la salida de una etapa es la entrada de la siguiente. En este proyecto, representa el camino que recorre el dato desde la URL de origen, pasando por la RAM y el análisis OCR, hasta transformarse en XML.
- **PEP 8:** Python Enhancement Proposal 8 (Propuesta de Mejora de Python N° 8). Es la guía de estilo oficial para escribir código en Python, que establece reglas de formato (como sangrías, límites de líneas y nombres de variables) para asegurar que el código sea limpio, legible y estandarizado.
- **URL:** Uniform Resource Locator (Localizador Uniforme de Recursos; dirección web que apunta al archivo contable en la red).
- **HTTP:** Hypertext Transfer Protocol (Protocolo de Transferencia de Hipertexto; protocolo utilizado para realizar la petición web de descarga).
- **BytesIO:** Clase de la biblioteca estándar de Python que crea un espacio en la memoria RAM para manipular datos binarios simulando un archivo físico.
- **PIL (Pillow):** Python Imaging Library (Biblioteca gráfica utilizada para decodificar, abrir y preparar las imágenes en RAM antes del análisis OCR).
- **Tesseract OCR:** Motor de código abierto para el Reconocimiento Óptico de Caracteres, encargado de analizar la imagen y extraer el texto plano.
- **TI:** Tecnologías de la Información.

1.4 Referencias

- [Documento Especificacion de requerimientos Gestion de Inventario .pdf](#)

2. Descripción General

2.1 Perspectiva del Producto

El sistema funcionará como un script automatizado basado en terminal (consola) compatible con plataforma Windows, diseñado para integrarse fácilmente en pipelines de datos y procesos automatizados de TI dentro de la empresa.

2.2 Funcionalidades del Producto

- Descarga de imágenes contables mediante peticiones HTTP estructuradas.
- Manipulación dinámica de flujos de datos en RAM (uso de BytesIO).
- Extracción óptica de caracteres con el motor Tesseract en idioma español.
- Encapsulación de información mediante generación automática de código XML.
- Manejo estandarizado de excepciones para evitar la interrupción de flujos contables ante enlaces rotos o caídas de red.

2.3 Características del Usuario

- **Supervisor / Jefe del Área de Programación / Analistas:** Encargados de ejecutar el pipeline técnico y auditar el código XML resultante.
- **Administradores del Sistema:** Responsables de configurar la ruta del motor de Tesseract dentro de los servidores del centro de práctica.

2.4 Restricciones

- El sistema requiere acceso activo a Internet para descargar los archivos contables.
- Se debe contar con el archivo ejecutable (tesseract.exe) instalado y configurado correctamente en el sistema operativo.

3. REQUERIMIENTOS FUNCIONALES

Caso de Uso 1: Extracción de texto mediante OCR en memoria

Caso de Uso	Extracción de texto mediante OCR en memoria
Actores	Sistema / Analista Programador
Precondición	El sistema debe recibir una URL válida de una factura o boleta en formato de imagen. Se debe contar con conectividad de red activa.
Descripción	Permite descargar de forma temporal la imagen contable a la memoria RAM, convirtiendo sus bytes crudos en un objeto manipulable antes de ejecutar la extracción OCR.
Flujo Principal	1. El usuario ejecuta el script de consola ingresando la URL del documento. 2. El sistema realiza una petición HTTP GET para adquirir el archivo contable. 3. El sistema valida el estado de la conexión utilizando <code>raise_for_status()</code>. 4. El sistema almacena los datos descargados en la memoria volátil a través de BytesIO. 5. El motor PyTesseract analiza el flujo binario e identifica los caracteres en idioma español (<code>lang='spa'</code>).
Postcondición	El texto en formato string plano es cargado temporalmente en una variable de memoria lista para ser estructurada.

Caso de Uso 2: Estructuración de datos y formateo XML

Caso de Uso	Estructuración de datos y formateo XML
Actores	Sistema
Precondición	El texto libre del documento contable debe haberse extraído exitosamente en el Caso de Uso 1.
Descripción	Toma la cadena de caracteres recuperada de la factura y la encapsula dentro de etiquetas jerárquicas estandarizadas para el flujo del sistema informático contable.
Flujo Principal	1. El sistema recupera el texto de la variable de memoria temporal. 2. El sistema genera de forma automática etiquetas XML <Documento> y <TextoOCR> usando f-strings. 3. El sistema incrusta el texto extraído como el elemento hijo de las etiquetas. 4. El sistema imprime el resultado formateado en la terminal y simula la finalización exitosa del proceso.
Postcondición	El sistema genera el string XML estructurado y listo para su consumo por sistemas de contabilidad externos de Gestpyme.

4. REQUERIMIENTOS DE INTERFACES DE USUARIO

Requerimiento de Interfaz 1: Interfaz de Configuración y Salida por Consola

Descripción: Dado que el prototipo del sistema opera como un script de automatización backend, la interfaz de entrada consiste en la edición directa del bloque de variables de configuración en el código fuente. La salida de datos se realiza a través de la terminal estándar (Standard Output).

Elementos:

- **Entrada de Datos:** Variable de configuración URL dentro del script principal, donde el programador define el enlace del documento contable a procesar.
- **Salida de Datos:** Consola de comandos (Terminal) que muestra la trazabilidad del proceso y el resultado XML final.

Validación: El sistema utiliza el método `raise_for_status()` de la librería *requests* para validar que la URL ingresada sea accesible y devuelva un flujo de datos válido.

- En caso de error en el enlace o en la decodificación de la imagen, la interfaz de consola debe capturar la excepción y mostrar un mensaje descriptivo mediante el bloque `except Exception as error`, evitando el cierre inesperado del programa.

5. REQUERIMIENTOS NO FUNCIONALES

RNF1: Rendimiento y procesamiento en memoria RAM

- **Descripción:** El script de Python debe procesar la carga y transformación de las imágenes de manera estricta en la memoria RAM (utilizando la librería BytesIO), evitando guardar copias persistentes de los archivos descargados en el disco duro.
- **Justificación:** Optimizar la velocidad de respuesta del pipeline OCR y reducir drásticamente el uso de recursos de almacenamiento secundario en el servidor de producción.

RNF2: Resiliencia ante fallas de red

- **Descripción:** El sistema debe contar con un manejo de excepciones exhaustivo (try-except) que impida la detención inesperada de los procesos contables en caso de caídas de red o URLs inválidas.
- **Justificación:** Garantizar la continuidad operacional de las tecnologías de información del centro de práctica.

RNF3: Compatibilidad y portabilidad

- **Descripción:** El programa debe ser compatible y ejecutable de forma transparente en entornos locales con Python 3.x y el binario correspondiente de Tesseract configurado.
- **Justificación:** Facilitar la portabilidad de las soluciones técnicas desarrolladas de manera que puedan ejecutarse de forma ágil por diferentes equipos de programación de la empresa.